

- **Tema:** Análise dos dados de desempenho de jogadores e times profissionais da NBA com o objetivo de caracterizar as funções dentro do jogo e definir que características do estilo de jogo são preferíveis para os times. Para isso será usado um dataset com estatísticas de jogadores e time por jogo.
- **Equipe:** Sin(args)²
 - Sidnei Junior, Rodrigo Santos, Antonio Ferreira e Lucas Ratusznei.
- **Obtenção e processamento de dados:**

Os dados foram obtidos de um repositório do github, contando com 5 arquivos csv no total, sendo 3 deles referentes a estatísticas de jogadores por jogo e outros 2 referentes a estatísticas de time por jogo.

Para a limpeza dos dados dos jogadores foi inicialmente removido as colunas de número de camisa e comentários, pois não eram necessários. Em seguida foi feito um preenchimento dos dados de posição que estavam vazios com valores do mesmo jogador, uma vez que as posições dos jogadores se repetem múltiplas vezes e após isso, foi transformado a coluna de minutos jogados de um formato mm:ss para um valor em minutos float, com os segundos sendo valores decimais. Como as estatísticas que seriam usadas nesse momento eram especificamente do jogador, foram excluídas colunas como data do jogo, nome do time, id do time, id do jogador, entre outros. Por fim foi feito um agrupamento dos valores por nome de jogador, nome de time, posição e anos da temporada em que o jogo aconteceu, fazendo uma média dos valores numéricos e depois foi recalculado as porcentagens de cestas, cestas de 3 pontos e arremessos livres.

Para a limpeza de dados de estatísticas de time, inicialmente foi criado uma coluna para a média de pontos “sofridos” e uma coluna de indicadores de “vitória ou derrota”, calculada com base nas estatísticas dos adversários, em seguida as estatísticas numéricas como pontos, assistências e rebotes foram agrupadas por temporada e equipe, e a sua média calculada. Com isso, algumas colunas como a data de jogo foi descartada pois não agregava informações e o ranking das equipes foi gerado com base nas vitórias, desempate por pontos médios na temporada.

Por fim, foi criado uma tabela com as colunas de nome do atleta, número de vitórias e minutos jogados total. Para isso foi pego as informações de vitórias da tabela inicial de jogo por time e em seguida foi feito um merge na id do time e na abreviação do nome do time.
- **Cobertura e distribuição dos dados:**




Figura 1

Analisando o gráfico 1, podemos observar que arremessos feitos (field goals made) estão bem equilibrados entre as posições, o que indica que jogadores de todas as posições possuem uma performance semelhante nessa métrica. No entanto, arremessos tentados apresentam uma grande diferença, com os pivôs (C) tentando significativamente menos chutes em comparação aos armadores (G), isso sugere uma maior eficiência dos pivôs. Essa maior eficiência também pode ser explicada pela menor tentativa de chutes de 3 pontos, que no geral tem um aproveitamento menor, pelos pivôs em comparação aos armadores, como fica evidente no gráfico.

Em relação aos outros aspectos, pivôs se destacam em tocos (bloqueios), rebotes ofensivos e rebotes defensivos, superando armadores e alas. Já as assistências e roubos de bola mostram uma inversão, com armadores se destacando mais nessas métricas. Os alas, por sua vez, ficam posicionados entre pivôs e armadores, tanto em rebotes quanto em assistências e roubos de bola. Perdas de bola apresentam um padrão mais equilibrado entre as posições, mas os pivôs tendem a cometer mais faltas em comparação aos outros jogadores.

Muitas das variáveis apresentam distribuições concentradas em valores mais baixos, a princípio achávamos que esse fenômeno ocorria por existir muitos jogadores com pouco tempo de quadra, que tendem a registrar valores muito baixos nas características em geral,

mas fomos refutados pelo histograma na Figura 2, já que podemos observar que eles são minoria. Mesmo assim, para análises futuras optamos por retirá-los, por não serem preferíveis para a análise geral de desempenho.




Figura 2

Com base na suposição de que jogadores com mais habilidades em suas posições tendem a permanecer mais tempo em quadra, o gráfico 3 mostra a relação entre o tempo de quadra e o número de vitórias na temporada. À medida que o número de vitórias aumenta, o tempo de quadra também tende a aumentar, indicando que jogadores com mais vitórias são mais frequentemente escalados para jogar mais minutos. adicionamos o tempo médio de quadra como uma variável e calculamos a correlação entre as características selecionadas e o tempo médio de quadra por jogo. As figuras 4, 5 e 6 mostram a matriz dessas correlações.




Figura 3

- **Identificação de padrões iniciais:**

Ao analisar a matriz de correlação, observamos que, para as três posições, as cestas de 2 pontos (tentadas e realizadas), os lances livres (tentados e realizados), as assistências e as faltas cometidas apresentam correlação semelhante com o tempo de quadra.

Em contraste, a correlação entre tempo de quadra e cestas de 3 pontos (tentadas e realizadas) sugere que essa habilidade é mais valorizada para jogadores da posição G, enquanto é menos preferida para a posição F, embora ainda apresente alguma relevância, e ainda menos relevante para a posição C.

Quanto aos rebotes ofensivos, estes parecem ter menor importância para as posições G e F, mas apresentam uma correlação significativamente maior com o tempo de quadra para a posição C, indicando uma maior relevância para essa função dentro do jogo. Apesar dos rebotes defensivos mostraram correlações altas e semelhantes para G e F, C apresenta um valor significativamente maior, indicando a importância dos rebotes de forma geral para essa posição. Além disso, os bloqueios também aparecem como uma característica desejável para a posição C, sendo menos relevantes para G e F.




Figura 4




Figura 5




Figura 6

- **Perguntas de pesquisa e explorações iniciais:**

O grupo decidiu fazer uma alteração nas perguntas que tínhamos escrito devido a uma falta de profundidade, dessa forma, para o andamento do trabalho, as perguntas a seguir são as que tentaremos responder.

- Que características do estilo de jogo são preferíveis para cada função?
- Quais funções, quando se aproximam mais das características preferíveis, beneficiam mais o número de vitórias da equipe na temporada?

Considerando o basquete como um esporte coletivo, definimos as seguinte perguntas para nos orientar à abarcar esse aspecto:

- Como a consistência coletiva dos times se alterou ao longo dos anos?

- Existe uma relação entre o desvio padrão do tempo de quadra e a qualificação da equipe durante a temporada?

Iniciamos a investigação para responder às duas primeiras perguntas analisando a distribuição das características dos jogadores. Primeiro, construímos um gráfico da estimativa de densidade para as características gerais.

A partir dessa visualização inicial, observamos que muitas características apresentaram distribuições bastante concentradas em valores baixos. Diante disso, selecionamos algumas variáveis específicas e aplicamos uma normalização dos dados.

Esse processo permitiu uma visualização mais clara das distribuições das características dos jogadores, como mostrado nas Figuras 7, 8 e 9.




Figura 7




Figura 8




Figura 9

Essa visualização se mostrou insuficiente para definir quais características são preferidas para cada posição, apesar de produzir alguns indicativos. Primeiramente, percebemos que as posições F e G tem uma distribuição muito semelhante de tentativas cestas de 2 pontos e cestas de 2 pontos feitas. Além disso, estas duas posições tem uma grande concentração de valores baixos para rebotes ofensivos, mas tem uma distribuição

de rebotes defensivos semelhante e concentrada em valores mais altos. G também tem uma distribuição um pouco mais concentrada em valores mais altos para assistências.

- **Discussão e próximos passos:**

Para os próximos passos do trabalho será feita a hipótese e também será escolhido o modelo para testar ou confirmar a hipótese pensada. Em relação aos dados, eles foram considerados suficientes e completos para o objetivo pensado. Em relação ao tema, não estamos completamente confortáveis, entretanto com o andamento do trabalho ele poderá ser aprimorado até uma versão final.