

Análise dos dados de desempenho de jogadores e times profissionais da NBA

Antônio Ferreira, Lucas Ratusznei, Rodrigo Santos, Sidnei Junior

Equipe: $\text{Sin}(\text{args})^2$

1 Introdução

Na NBA, os jogadores e suas características são essenciais para o time, de forma que alguns jogadores têm um impacto positivo tão grande que quando há algum impedimento de jogar o seu time perde parte da sua efetividade. O tema escolhido é importante para entender detalhes do jogo, como posições e características, que podem contribuir para o desenvolvimento e aprimoramento de estratégias.

O grupo desenvolveu três perguntas a serem respondidas durante o projeto, a partir da análise de um *dataset* com estatísticas de jogadores e times, com o objetivo de caracterizar as funções dentro do jogo, definir que características do estilo de jogo são preferíveis para os times e contribuem para maximizar o número de vitórias.

As perguntas desenvolvidas são:

1. Quais características do estilo de jogo são preferíveis para cada função? Quais funções, quando se aproximam mais das características preferíveis, beneficiam mais, em relação às outras funções, o número de vitórias da equipe na temporada?
2. Quais funções, quando se aproximam mais das características preferíveis, beneficiam mais, em relação às outras funções, o número de vitórias da equipe na temporada?
3. Existem posições em que a substituição de bons jogadores é mais difícil?

Para respondê-las foram usados gráficos, modelos estatísticos e detecção de anomalias, respectivamente. Os resultados obtidos foram, em geral, satisfatórios, ainda que apresentem limitações.

2 Processamento de dados

Para a limpeza dos dados dos jogadores foi inicialmente removido as colunas de número de camisa e comentários, pois não eram necessários. Em seguida foi feito um preenchimento dos dados de posição que estavam vazios com valores do mesmo jogador, uma vez que as posições dos jogadores se repetem múltiplas vezes, e após isso, a coluna de minutos jogados foi transformada de um formato mm:ss para valores reais. Para responder as perguntas 1 e 2, foram excluídas colunas como data do jogo, nome do time, id do time, id do jogador, entre outros. Por fim foi feito um agrupamento dos valores por nome de jogador, nome de time, posição e anos da temporada em que o jogo aconteceu, fazendo uma média dos valores numéricos. Depois foi recalculado as porcentagens de cestas, cestas de 3 pontos e arremessos livres.

Para a limpeza de dados de estatísticas de time, inicialmente foi criada uma coluna para a média de pontos “sofridos” e uma coluna de indicadores de “vitória ou derrota”, calculada com base nas estatísticas dos adversários, em seguida as estatísticas numéricas como pontos,

assistências e rebotes foram agrupadas por temporada e equipe, e a sua média calculada. Com isso, algumas colunas, como a data de jogo foram descartada pois não agregava informações e o ranking das equipes foi gerado com base nas vitórias, usando como critério de desempate os pontos médios na temporada.

Também foi criada uma tabela com as colunas de nome do atleta, número de vitórias e minutos jogados total. Para isso foi pego as informações de vitórias da tabela inicial de jogo por time e em seguida foi feito um merge no ID do time e na abreviação do nome do time.

3 Resultados

3.1 Quais características do estilo de jogo são preferíveis para cada função?

Essa pergunta inicialmente havia sido respondida utilizando um gráfico de barras, entretanto, após a recomendação do professor, isso foi alterado para três gráficos de teia para facilitar a visualização. Esses gráficos são apresentados de forma sobreposta na Figura 1.




Figura 1: Gráfico radial com as médias das características por posição

O resultado foi obtido observando quais características mais se destacavam em cada posição. Após as características de maiores médias serem escolhidas, notou-se que as posições tinham diversas características que não se destacavam, mas eram estavam presentes de forma semelhante para as diferentes posições. Assim, optou-se por um método iterativo para selecionar as características, no qual era feita uma seleção e se alguma delas se repetiam em todas as posições, essa era descartada da análise e as características eram selecionadas novamente até

que não haver características que se comuns a todas as posições. Foram selecionadas 4 características por posição, de forma arbitrária, considerando a quantidade total de características. Dessa forma, chegou-se à seleção das seguintes características para cada posição:

- **Pivô (C/Center):** Tiros livres acertados (*FreeThrowsMade*), rebotes defensivos (*reboundsDeffensive*), bloqueios (*blocks*) e rebotes ofensivos (*reboundsOffensive*).
- **Ala (F/Forward):** Tentativas de três pontos (*ThreePointsAttempted*), rebotes defensivos (*reboundsDeffensive*), roubos (*steals*) e *turnover*.
- **Armador (G/Guard):** Tentativas de três pontos (*ThreePointsAttempted*), assistências (*assist*), roubos (*steals*) e *turnover*.

3.2 Quais funções, quando se aproximam mais das características preferíveis, beneficiam mais, em relação às outras funções, o número de vitórias da equipe na temporada?

Para responder a nossa segunda pergunta foi preciso desenvolver uma forma de medir a qualidade da composição de cada função do time dentro de uma partida, para, a partir daí, estimarmos qual função tem mais influência sobre um resultado de vitória.

Tendo selecionado estatísticas que caracterizam as três funções do jogo ao responder a pergunta 1, consideramos valores maiores para essas características como preferíveis para a função. Em seguida, realizamos um cálculo de uma pontuação de cada jogador em cada partida de acordo com as características preferíveis para a sua função no jogo. Essa pontuação individual da posição consistiu na média entre os valores das características preferíveis da função do indivíduo. Esses dados foram normalizados para que pudessem ser comparados entre si.

Tendo calculado uma pontuação individual da posição por jogo, realizamos a soma dessas pontuações entre todos os jogadores de mesma posição em cada jogo, resultando em uma pontuação coletiva da posição para cada time por jogo. Tínhamos também o dado de vitória e derrota do time em cada partida de forma categórica. Então realizamos uma junção entre tabela de estatísticas por jogador e a tabela de estatísticas por time e aplicamos uma dummificação para que esse dado fosse utilizado como variável dependente em uma regressão logística. As variáveis independentes dessa regressão foram as pontuações coletivas de pivô, armador e ala do time. Dessa forma, esperávamos obter a influência da qualidade da composição de cada posição sobre o resultado de vitória no jogos.

O modelo teve uma precisão de 57% e um recall de 56%. Para validar a significância estatística dos resultados utilizamos o módulo statsmodels, obtivemos um pseudo r-quadrado de 0.03

```

Optimization terminated successfully.
Current function value: 0.671772
Iterations 5
Logit Regression Results
=====
Dep. Variable:          W      No. Observations:      26652
Model:                Logit   Df Residuals:          26648
Method:               MLE     Df Model:              3
Date:                Thu, 26 Jun 2025   Pseudo R-squ.:        0.03083
Time:                21:23:26   Log-Likelihood:       -17904.
converged:           True     LL-Null:              -18474.
Covariance Type:     nonrobust   LLR p-value:          1.128e-246
=====

```

	coef	std err	z	P> z	[0.025	0.975]
const	-2.3819	0.078	-30.613	0.000	-2.534	-2.229
c_score	2.6346	0.099	26.661	0.000	2.441	2.828
f_score	2.3627	0.106	22.332	0.000	2.155	2.570
g_score	1.5981	0.101	15.769	0.000	1.399	1.797

Figura 2: Tabela com resultados da regressão logística

Para identificar qual posição teve a maior contribuição na probabilidade de vitória, extraímos e analisamos os coeficientes do modelo, dessa forma obtemos pivôs (C) com um coeficiente de 2,60, alas (F) com 2,33 e armadores (G) com 1,57. Sendo assim, concluímos que os pivôs apresentaram um fator mais determinante para a vitória, seguidos pelos alas. Isso negou nossa hipótese inicial, de que posições mais especializadas (armadores e pivôs) tivessem mais influência na vitória que posições menos especializadas (alas).




Figura 3: Comparação entre os coeficientes de regressão logística

3.3 Existem posições em que a substituição de bons jogadores é mais difícil?

Nesta análise, avaliamos a dificuldade de substituição de cada posição no time, com base no desempenho da equipe quando jogadores daquela posição estão ausentes ou jogaram menos tempo que sua média na temporada. Consideramos que quando a ausência de um bom jogador de uma posição resulta em uma maior queda de desempenho do seu time em comparação às demais, essa posição é mais difícil de substituir.

Utilizamos o algoritmo One-Class SVM para detectar anomalias no tempo de quadra, pois após pesquisar sobre os algoritmos existentes, esse pareceu se encaixar mais em nossos dados e na nossa pergunta, uma vez que não tínhamos rotulado de fato quando os jogadores haviam sido substituídos, mas sabíamos qual era o tempo de quadra comum do jogador a partir da média do tempo de quadra dele na temporada.

Então, para identificar jogadores com padrões anômalos de tempo de quadra, iniciamos calculando a média de minutos jogados por cada jogador durante a temporada 2022-23. Em seguida, filtramos esse conjunto de dados "*inliers*" contendo apenas jogos onde os jogadores atuaram por pelo menos 75% de sua média de minutos. Essa filtragem foi usada para treinar o modelo apenas com presenças de quadra consideradas normais.

Após o treinamento, aplicamos o modelo a todos os jogos da temporada 2022-23. Para validar os resultados, criamos visualizações do tempo de quadra ao longo da temporada para jogadores específicos, destacando os jogos identificados como anômalos. Uma análise adicional concentrou-se especificamente em jogos onde os jogadores atuaram menos que sua média sazonal.

Para avaliar o impacto das anomalias de tempo de quadra no desempenho do time, criamos uma métrica de diferencial de pontos (Plus-Minus) por jogo. Através do merge dos dados de totais da temporada regular, calculamos a diferença entre os pontos marcados pelo time e os pontos sofridos do adversário e usamos esse dado para representar o desempenho coletivo da equipe.

Os dados de anomalias previamente identificados foram integrados com as informações de Plus-Minus. Para garantir que analisássemos apenas jogadores relevantes, optamos por selecionar aqueles com maior média de minutos por temporada em cada posição. Esta abordagem aumenta a nossa chance de avaliar o impacto de anomalias em jogadores importantes, cuja ausência ou performance reduzida teria maior probabilidade de afetar o resultado da equipe. Então, selecionamos os 10 principais jogadores de cada posição que apresentaram anomalia e comparamos o desempenho da equipe em duas situações: jogos onde o jogador teve tempo de quadra significativamente reduzido e jogos com padrão normal de minutos.

Podemos observar nas tabelas 1, 2 e 3 que os times que tiveram seus alas ausentados apresentaram um desempenho consideravelmente pior quando isso ocorreu. Assim, podemos concluir que os alas foram mais difíceis de serem substituídos naquela temporada.

4 Limitações/trabalhos futuros

Na primeira pergunta, os resultados foram obtidos apenas observando gráficos teias, o que não é, em si, uma forma incorreta de responder à pergunta. Entretanto, poderíamos obter melhores resultados utilizando um modelo de regressão em que a variável dependente representasse o desempenho positivo do jogador. Porém, também tivemos dificuldades em estabelecer essa variável dependente.

Tabela 1: Tabela de Plus-Minus - Grupo C

Jogador	Plus-Minus (com anomalia)	Plus-Minus (sem anomalia)
Anthony Davis	14.0	-18.666667
Deandre Ayton	-13.0	0.375000
Rudy Gobert	1.0	3.000000
Jarrett Allen	2.0	2.666667
Jonas Valanciunas	-1.5	-2.500000
Jusuf Nurkic	-10.0	-1.200000
Jalen Smith	-3.0	-1.200000
Aleksej Pokusevski	-1.5	-5.000000
Santi Aldama	7.0	-18.666667
Bam Adebayo	-13.0	-4.250000

Tabela 2: Tabela de Plus-Minus - Grupo F

Jogador	Plus-Minus (com anomalia)	Plus-Minus (sem anomalia)
Isaac Okoro	-17.0	2.666667
De'Andre Hunter	-17.0	8.000000
RJ Barrett	-5.0	-7.000000
Khriston Middleton	4.0	29.000000
Kyle Anderson	-7.0	0.625000
Chris Duarte	-2.0	-4.250000
Reggie Bullock	-4.0	3.428571
Nicolas Batum	-23.0	-0.666667
Marvin Bagley III	-26.0	6.666667
Jeremy Sochan	-8.0	15.600000

Tabela 3: Tabela de Plus-Minus - Grupo G

Jogador	Plus-Minus (com anomalia)	Plus-Minus (sem anomalia)
Dejounte Murray	-24.0	-4.500000
Luka Doncic	4.0	2.500000
Anthony Edwards	8.0	-1.250000
Terrence Ross	-8.0	3.750000
Bradley Beal	11.0	0.714286
Kevin Huerter	-5.0	-4.000000
D'Angelo Russell	-13.0	-5.285714
Alex Caruso	-29.0	-2.000000
Devin Booker	3.0	-1.750000
Derrick White	16.0	3.400000

Para a segunda pergunta, foi calculado um score para cada posição e, em seguida, utilizando o resultado dos jogos como variável dependente em um algoritmo de regressão logística obtivemos um resultado satisfatório. Mesmo assim, o uso de variáveis de controle poderia contribuir para que obtivéssemos melhores resultados. Além disso, houve uma demora para encontrar uma forma de medir a qualidade das posições do time, havendo muitos ajustes e reajustes no modelo. Entendemos que isso se deu em virtude da complexidade dos dados que estávamos analisando.

Tivemos dificuldades em virtude da falta de conhecimento sobre aprendizado de máquina ao aplicar o modelo usado para responder à terceira pergunta. E também não pudemos processar os dados de todas as temporadas que tínhamos por causa de algumas limitações de hardware, o que prejudica a segurança nos nosso resultado, uma vez que tenhamos encontrado um número pequeno de jogadores com anomalias.

5 Uso de ChatGPT

O grupo usou a LLM para fazer consultas sobre o uso das ferramentas utilizadas ao longo do trabalho - especialmente as bibliotecas Python.